

Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт (национальный исследовательский
университет)»
Физтех-школа аэрокосмических технологий
Кафедра логистических систем и технологий

Направление подготовки: 27.03.03 Системный анализ и управление

Направленность (профиль) подготовки: Системный анализ и управление в технических,
экономических и социальных системах

**ИССЛЕДОВАНИЕ И РАЗРАБОТКА МЕТОДОВ ЛОКАЛЬНОГО ОПРЕДЕЛЕНИЯ
ЭМОЦИОНАЛЬНОЙ ОКРАСКИ ТЕКСТОВЫХ СООБЩЕНИЙ В МОБИЛЬНЫХ
СИСТЕМАХ**

(бакалаврская работа)

Студент:

Саманюк Эвелина Эдуардовна

(подпись студента)

Научный руководитель:

Булычев Александр Викторович,
доцент, к.т.н.

(подпись научного руководителя)

Москва 2026

Аннотация

В работе исследуется задача локального определения эмоциональной окраски коротких русскоязычных сообщений для приватного анализа переписки на устройстве пользователя. Цель работы – обоснованный выбор модели по совокупности критериев (качество классификации, размер, задержка) и демонстрация прикладного сценария. Задачи: обзор подходов; формирование единого протокола сравнения; сравнение широкого спектра моделей с подбором гиперпараметров; исследование переносимости и доменной адаптации; реализация модуля визуализации динамики.

Эксперименты выполнены на корпусах RuGoEmotions и CEDR; на едином протоколе сравнено около двадцати моделей, а основной метрикой отбора служит расхождение предсказанного и целевого распределений по классам. По качеству распределения лидирует дообученная модель RuBERT-tiny2, однако лёгкая линейная модель на символьных n-граммах с логистической регрессией (logreg-char) почти не уступает ей, оставаясь на порядки компактнее (2,7 МБ). Линейные модели теряют около десяти процентных пунктов точности на нативном русском, но разрыв устраняется добавлением небольшого объёма нативных данных, после чего logreg-char достигает на CEDR точности 0,72.

На основании работы в качестве локально запускаемой модели рекомендуется logreg-char: дообученная на небольшом наборе нативных данных, она достигает качества, сопоставимого с дообученным трансформером; сам трансформер при этом остаётся ориентиром качества при ослаблении ресурсных ограничений. Реализован прикладной модуль визуализации динамики эмоциональной окраски (эмоциональный таймлайн), развёрнутый как технологическая демонстрация на платформе Hugging Face Spaces с импортом диалогов и интерактивным интерфейсом.

Оглавление

Обозначения и сокращения	4
Введение	5
1 Анализ предметной области и обзор литературы	7
1.1 Актуальность и постановка проблемы	7
1.2 Обзор существующих подходов	8
1.3 Обоснование выбора моделей для сравнения	11
1.4 Выводы по главе	12
2 Постановка задачи и выбор методов решения	13
2.1 Формальная постановка задачи	13
2.2 Математический аппарат и обоснование выбранных методов	14
2.3 Выводы по главе	17
3 Реализация и экспериментальная проверка	19
3.1 Описание реализации	19
3.2 Эксперименты и результаты	20
3.2.1 Данные и протокол	20
3.2.2 Полный лидерборд	22
3.2.3 Кросс-доменная проверка	23
3.2.4 Доменная адаптация	24
3.2.5 Итоговый подбор гиперпараметров и выбор модели	25
3.2.6 Калибровка уверенности	27
3.3 Эмоциональный таймлайн и концепт календаря	29
3.4 Анализ результатов	32
3.5 Сводное сравнение и применимость	34
3.6 Ограничения, этика и приватность	36
3.7 Выводы по главе	36
Заключение	38
Список использованных источников	40
Приложение А. Дополнительные материалы	44

Обозначения и сокращения

BKP выпускная квалификационная работа.

NLP обработка естественного языка.

TF-IDF статистическая мера важности термина в документе относительно корпуса.

BERT трансформерная языковая модель для получения контекстных представлений текста.

RuBERT русскоязычная адаптация BERT-подобной модели.

DeBERTa вариант BERT с раздельным кодированием содержания и позиции токенов.

HPO подбор гиперпараметров модели (hyperparameter optimization).

RuGoEmotions русскоязычная адаптация корпуса GoEmotions, полученная машинным переводом.

CEDR нативный русскоязычный корпус эмоций (Corpus for Emotions Detecting in Russian-language text).

KL дивергенция Кульбака–Лейблера – мера расхождения между распределениями.

JS дивергенция Йенсена–Шеннона – ограниченная симметричная мера расхождения.

ECE ожидаемая калибровочная ошибка (expected calibration error).

F1 гармоническое среднее precision и recall; macro-F1 – её усреднение по классам.

P50, P95 медиана и 95-й перцентиль задержки инференса.

CPU центральный процессор.

CSV табличный текстовый формат хранения данных.

Введение

Актуальность темы. Мобильная клавиатура и другие компоненты текстового ввода являются промежуточным программным слоем между пользователем и большинством приложений, через который проходят наиболее чувствительные фрагменты пользовательского ввода. От современного ввода ожидается интеллектуальная поддержка, однако высокое качество таких функций нередко достигается за счёт обработки текста на удалённых серверах, что порождает противоречие между удобством и приватностью. Это повышает интерес к полностью локальным алгоритмам обработки текста, выполняемым на устройстве и не требующим передачи данных наружу.

Одной из перспективных локальных функций является определение эмоциональной окраски коротких сообщений с последующим построением динамики во времени. Однако перенос такой функции в локальный сценарий нетривиален: модель должна обеспечивать приемлемое качество, давать калиброванные оценки распределения по классам, иметь малые размер и задержку и сохранять устойчивость на реальном русском языке. При этом задача эмоциональной классификации именно коротких русскоязычных сообщений исследована заметно слабее смежных: подавляющее большинство русскоязычных корпусов и готовых моделей ориентированы на тональность отзывов, новостей или отношения к именованным сущностям, тогда как нативных размеченных по эмоциям корпусов разговорной переписки крайне мало, а значительная часть доступных данных получена машинным переводом, что ставит вопрос переносимости моделей на реальный русский язык. Таким образом, актуальность настоящей выпускной квалификационной работы (ВКР) определяется необходимостью обоснованного выбора модели определения эмоциональной окраски коротких русскоязычных сообщений, пригодной для локального применения.

Объект исследования. Объектом исследования являются методы локальной обработки коротких текстовых сообщений в пользовательских интерфейсах текстового ввода.

Предмет исследования. Предметом исследования являются сравнительные характеристики моделей определения эмоциональной окраски коротких русскоязычных сообщений – качество классификации, калибровка оценок, вычислительные ресурсы и устойчивость к смене домена, – определяющие их применимость в составе локального модуля.

Цель работы. Целью работы является сравнение подходов и обоснованный выбор модели локального определения эмоциональной окраски коротких русскоязычных сообщений по совокупности этих характеристик, а также демонстрация прикладного сценария анализа динамики эмоциональной окраски переписки.

Задачи работы.

1. Провести обзор подходов и доступных моделей для оценки эмоциональной окраски коротких текстовых сообщений.

2. Сформировать единый протокол сравнения: схему эмоциональных классов, набор метрик качества и калибровки, обучающие и проверочные данные, включая нативную кросс-доменную проверку.
3. Сравнить широкий спектр моделей – от словарных и линейных до трансформерных – с подбором гиперпараметров и выбрать модель по совокупности критериев.
4. Исследовать устойчивость моделей к смене домена и эффект доменной адаптации.
5. Реализовать прикладной модуль визуализации динамики эмоциональной окраски переписки и описать концепт эмоционального календаря.

Методы исследования. В работе используются анализ научно-технической литературы и существующих решений, сравнительный анализ моделей обработки естественного языка, экспериментальная оценка качества классификации, калибровки и ресурсных характеристик, а также кросс-доменная проверка и эксперимент по доменной адаптации.

Научно-теоретическая и практическая значимость. Научно-теоретическая значимость состоит в систематизации подходов к локальному анализу эмоциональной окраски коротких сообщений и в выявлении факторов, влияющих на их применимость, – в частности, влияния домена данных и калибровки. Практическая значимость заключается в обоснованном выборе лёгкой локально запускаемой модели и в реализации исследовательского прототипа визуализации динамики эмоциональной окраски без передачи исходных сообщений на внешние серверы.

Научная новизна. Научная новизна работы состоит в следующем. Во-первых, на едином протоколе, включающем калибровку оценок и кросс-доменную проверку, сопоставлен широкий спектр моделей (около двадцати, от словарных до трансформерных) для семиклассовой классификации эмоциональной окраски коротких русскоязычных сообщений. Во-вторых, эмпирически показано, что лёгкая линейная модель размером около 2,7 МБ при добавлении небольшого объёма нативных размеченных данных достигает на нативном русском домене качества, сопоставимого с дообученным трансформером, превосходящим её по размеру на два порядка, что обосновывает её пригодность для полностью локального запуска.

Апробация результатов. Апробация выполнена в форме экспериментальной проверки на корпусах RuGoEmotions и CEDR по метрикам качества, калибровки и ресурсным характеристикам, а также демонстрации полного пользовательского сценария на русскоязычных диалогах.

Глава 1. Анализ предметной области и обзор литературы

1.1. Актуальность и постановка проблемы

Мобильная клавиатура и другие компоненты текстового ввода являются промежуточным программным слоем между пользователем и большинством приложений, в которых ведется текстовая коммуникация. Через них проходят наиболее чувствительные фрагменты пользовательского ввода: личные сообщения, поисковые запросы, фрагменты рабочей переписки, имена, адреса и иные персональные данные. Одновременно от современного текстового ввода ожидается интеллектуальная поддержка – исправление опечаток, предсказание слов, персонализация и контекстные подсказки. Высокое качество этих функций нередко достигается за счет обработки пользовательского текста на удаленных серверах, что порождает противоречие между качеством интеллектуальных функций и требованиями приватности.

Одним из направлений разрешения этого противоречия является федеративное обучение: как показали Хард и др. и Ван и др., модель можно обучать на устройствах пользователей без выгрузки исходных текстов на сервер [1, 2]. Однако и федеративный подход не дает полной гарантии приватности: Сулиман и Лейт показали, что из обновлений федеративной языковой модели в сценарии предсказания слов могут восстанавливаться фрагменты пользовательского ввода [3]. Это делает самостоятельно значимым направление полностью локальной обработки текста, при которой ни сами сообщения, ни обучающие обновления не покидают устройство.

Среди возможных локальных интеллектуальных функций отдельный интерес представляет определение эмоциональной окраски коротких сообщений. На его основе можно строить динамику эмоциональной окраски отправленных сообщений во времени – например, в виде эмоционального таймлайна или календаря – при сохранении всех вычислений на устройстве. Однако перенос такой функции в локальный сценарий нетривиален: модель должна не только обеспечивать приемлемое качество классификации, но и работать при ограниченных вычислительных ресурсах, давать пригодные для агрегации оценки распределения по классам и сохранять устойчивость на реальном разговорном русском языке.

При этом задача определения эмоций именно в коротких русскоязычных сообщениях исследована существенно слабее смежных. Большинство доступных русскоязычных работ и корпусов ориентированы на тональность отзывов, новостных текстов или отношения к именованным сущностям, тогда как личная переписка отличается краткостью, разговорным стилем, опечатками, эмодзи и индивидуальной манерой. Дополнительную сложность создает дефицит размеченных нативных данных: значительная часть доступных русскоязычных ресурсов получена переводом англоязычных корпусов, что ставит вопрос о переносимости моделей на реальные русскоязычные тексты.

Таким образом, актуальность работы определяется необходимостью выбора модели определения эмоциональной окраски коротких русскоязычных сообщений, пригодной для локального применения. Центральной задачей является не отдельная модель, а сравнительный анализ широкого спектра подходов по критериям отбора (качество классификации, размер, задержка) с дополнительным анализом калибровки оценок и устойчивости к смене домена как свойств, определяющих применимость, и с последующей демонстрацией прикладного сценария локального анализа эмоциональной окраски переписки.

1.2. Обзор существующих подходов

Короткие пользовательские сообщения существенно отличаются от длинных документов и формальных текстов: они состоят из одного-двух предложений, содержат опечатки, сокращения, разговорные конструкции, эмодзи, междометия и неполный контекст. Поэтому методы анализа эмоций, хорошо работающие на длинных отзывах или новостях, не всегда напрямую применимы к сообщениям в мессенджерах.

Ориентиром для исследования эмоций в коротких текстах служат работы по эмоциональной классификации в социальных сетях. Так, в системе Базиотиса и др. для SemEval использовались рекуррентные сети с механизмом внимания [4], а в подходе DeepMoji (Фельбо и др.) предсказание эмодзи на большом корпусе твитов применялось как форма слабого обучения для анализа тональности и эмоций [5]; эмодзи естественно присутствуют в коротких сообщениях и часто несут эмоциональный сигнал. Значимым ресурсом является набор GoEmotions, предложенный Демски и др. [6] и содержащий десятки тысяч коротких комментариев, размеченных по 27 категориям эмоций и нейтральному классу. Эта работа показывает, что даже при использовании BERT тонкая эмоциональная разметка остается умеренной по качеству, что указывает на неустойчивость детальной классификации на коротких текстах и обосновывает применение укрупненной схемы эмоций.

Для русскоязычной задачи доступных размеченных по эмоциям корпусов немного. Один из практичных вариантов – RuGoEmotions, русскоязычная адаптация GoEmotions, полученная машинным переводом [7]. Известно, что перевод порождает отдельный лингвистический эффект: как показали Волански и др., переведенные человеком тексты систематически отличаются от исходных, образуя так называемый «translationese» [8]. Это явление изучено прежде всего для перевода, выполненного человеком, однако есть основания ожидать систематических артефактов и при машинном переводе; в любом случае качество модели на переведенном корпусе не гарантирует такого же качества на исходно русскоязычных текстах. В отличие от переводных данных, существуют и нативные русскоязычные эмоциональные корпуса: так, набор CEDR, собранный Сбоевым и др., содержит свыше девяти тысяч русскоязычных сообщений из социальных сетей, новостей и блогов, размеченных по нескольким

базовым эмоциям [9]. В обзоре Котельникова показано, что русскоязычные корпуса существенно различаются по домену, схеме разметки и качеству аннотации [10], а Лукашевич и Русначенко отмечают, что оценочные конструкции в русском языке зависят не только от отдельных слов, но и от предикатов и участников ситуации [11]. Поэтому перенос модели между корпусами требует осторожности, а нативные данные ценны как проверка реальной применимости.

Подходы к эмоциональной классификации можно разделить на несколько групп. Первая – словарные методы. Классическим примером является словарь NRC Emotion Lexicon (Мохаммад и Тёрни) [12], где словам сопоставляются эмоции, а оценка текста строится по присутствующим лексическим признакам. Лингвистическую основу для русского языка дают работы по эмотивности Шаховского и Бабенко [13, 14]. Словарные методы просты, интерпретируемы, имеют крайне малый размер и полностью локальны, поэтому удобны как понятный ориентир для сравнения; их ограничение – слабый учет контекста, отрицаний и переносного смысла. Как показывают Котельникова и др., в русскоязычном анализе тональности лексиконы остаются конкурентоспособным простым подходом даже при сравнении с BERT-подобными моделями [15].

Вторая группа – линейные классификаторы на разреженных признаках. Текст представляется взвешенными по TF-IDF словными и символьными n-граммами [16, 17], поверх которых обучается линейная модель – логистическая регрессия [18, 19] или гребневая регрессия. Символьные n-граммы особенно полезны для коротких сообщений, так как частично компенсируют опечатки, удлинения букв и морфологические варианты. Этот класс методов воспроизводим, быстр и компактен; при этом выбор между логистической и гребневой регрессией влияет не только на точность, но и на калибровку выдаваемых вероятностей, что важно при их последующей агрегации.

Третья группа – модели на подсловных представлениях. Модель fastText (Жулен и др.) классифицирует текст на основе словных и подсловных признаков и обучает компактные плотные представления [20]; предложены и методы сжатия таких моделей [21]. fastText учитывает морфологию и часть опечаток, оставаясь очень быстрым, что делает его самостоятельным легким кандидатом, методологически отличным от TF-IDF с логистической регрессией. К классическим методам относится также наивный Байес на TF-IDF-признаках; его модификации, в частности complement naïve Bayes (Ренни и др.), специально адаптированы к несбалансированным текстовым данным [22]. Применяются и ансамбли решающих деревьев, однако на разреженных текстовых признаках они, как правило, уступают линейным моделям и требуют существенно большего объема памяти [19].

Четвертая группа – трансформерные модели. Архитектура Transformer (Васвани и др.) основана на механизме self-attention [23]; на ней построена модель BERT (Девлин и др.) с двунаправленным контекстным представлением [24], для русского языка адаптированная

в RuBERT Куратовым и Архиповым [25]. Развитием BERT является DeBERTa (Хэ и др.) с раздельным кодированием содержания и позиции токенов [26]. Трансформеры обычно дают более высокое качество, но требуют больше памяти и вычислений; для снижения этих требований предложены облегченные варианты – DistilBERT (Сан и др.) [27] и MobileBERT (Сун и др.) [28], а перенос на устройства, как показывают Панопулос и др. и Рахман и др., требует дополнительных оптимизаций и квантования [29, 30]. При этом Разова и др. показывают, что русскоязычные BERT-подобные модели в значительной мере опираются на тональную лексику [31], что связывает словарные и нейросетевые подходы не как взаимоисключающие, а как частично пересекающиеся. Применимость трансформера в локальном сценарии поэтому требует отдельной оценки по размеру и задержке инференса.

Отдельный вопрос – выбор метрик оценки. Для несбалансированных классов стандартom является macro-усредненная F1-мера, применяемая, в частности, Голубевым и др. в задаче RuSentNE [32]. Однако если результат классификации используется не только как итоговая метка, но и как распределение оценок по классам – например, для построения динамики эмоций во времени, – то важно качество самого распределения и его калибровка. Как показали Го и др., современные нейросетевые модели нередко плохо откалиброваны, то есть их уверенность не соответствует фактической вероятности правильного ответа [33]. Это мотивирует оценивать модели не только по точности, но и по тому, насколько предсказанное распределение по классам согласуется с целевым, измеряя это согласие как расхождение между распределениями; конкретная метрика такого расхождения вводится во второй главе.

Поскольку основной обучающий корпус является переводным, а целевые тексты – нативными русскоязычными сообщениями, существенным становится вопрос переноса модели между доменами. Обзор Рампони и Планк по доменной адаптации в обработке естественного языка [34] показывает, что снижение качества при смене домена – типичная проблема, а одним из доступных способов ее смягчения является дообучение на небольшом объеме данных целевого домена. С учетом возможных артефактов перевода это означает, что высокое качество модели на переводном корпусе необходимо проверять на нативных данных. Заметный разрыв между ними можно интерпретировать как признак того, что модель частично подстроилась под особенности перевода, а не научилась устойчивым языковым признакам.

Наконец, переход от классификации отдельного сообщения к оценке эмоциональной окраски за период времени имеет методологические аналогии. В психологии близкой постановкой является ecological momentary assessment (Шиффман и др.) – повторная оценка состояния в естественной среде [35]. Примером текстовой агрегации служит hedonometrics (Доддс и др.), где по сообщениям социальных сетей строятся временные ряды коллективного уровня счастья [36]. Для агрегации оценок нескольких сообщений в одном временном окне естественно усреднять выходные распределения модели, что согласуется с принципом линейного комбинирования выходов классификаторов, описанным Тюмером и Гошем [37] и

сохраняет больше информации, чем голосование по итоговым меткам. При этом выходные оценки следует трактовать как относительную уверенность модели, а не как психологическое измерение состояния пользователя [33].

Сравнение рассмотренных работ показывает, что у каждой группы методов своя область применимости: словарные подходы просты и приватны, но ограничены по качеству; линейные модели на n -граммных признаках дают хороший баланс скорости, размера и точности, но зависят от обучающего корпуса и его домена; подсловные и наивно-байесовские модели образуют дополнительные легкие компромиссы; трансформеры потенциально точнее, но тяжелее и требуют оптимизации для локального запуска. При этом сквозными для всех подходов оказываются три фактора, недостаточно освещенные в литературе применительно к коротким русскоязычным сообщениям: качество калиброванного распределения по классам, устойчивость к смене домена и ресурсная пригодность для локального запуска. Именно совокупность этих факторов определяет выбор модели в настоящей работе.

1.3. Обоснование выбора моделей для сравнения

Из обзора следует, что для рассматриваемой задачи нет единственного очевидно лучшего метода: разные семейства моделей выигрывают по разным критериям. Поэтому в работе принят не выбор одной модели заранее, а сравнительный анализ широкого спектра подходов на едином протоколе: по критериям отбора – качеству классификации, размеру модели и задержке инференса – с дополнительной оценкой калибровки распределения и устойчивости к смене домена как свойств, определяющих применимость. Эти критерии имеют разную природу, и их искусственное объединение в одну взвешенную формулу создавало бы ложное ощущение точности; поэтому сравнение проводится как анализ компромиссов, а не как максимизация одного числа.

Сравниваемый набор моделей выстроен как шкала возрастающей сложности. Нижнюю границу задают тривиальные базовые модели – равномерное распределение, наиболее частый класс и распределение частот классов обучающей выборки; они показывают, какой уровень метрик достижим без какого-либо понимания текста. Далее следуют интерпретируемые словарные модели: ручной лексикон, который без обучения остается по качеству вблизи тривиального уровня и служит дополнительной нижней границей, и обучаемый по данным лексикон – уже полноценный компактный кандидат. Затем идут линейные модели на TF-IDF-признаках (логистическая и гребневая регрессия на символьных, словных и объединенных n -граммах) как основные кандидаты для локального запуска, подсловная модель fastText и наивный Байес как дополнительные компактные варианты, а также ансамбли решающих деревьев, включенные для полноты картины. Верхнюю границу качества задают компактные трансформерные модели: дообученная русскоязычная RuBERT-tiny2 и готовые

русскоязычные эмоциональные модели на основе RuBERT и DeBERTa.

Такой состав позволяет одновременно ответить на два вопроса. Во-первых, базовые модели и трансформеры-потолки очерчивают рамку: они показывают, какой прирост качества дает усложнение модели и какой ценой по размеру и задержке он достается. Во-вторых, между собой соревнуются легкие обучаемые семейства – именно они являются реалистичными кандидатами для локального запуска. При этом для прикладного сценария важны не только точность и полнота: распределение оценок должно быть пригодно для агрегации во времени, а модель – сохранять качество на нативных русскоязычных текстах, а не только на переводном корпусе. Поэтому в сравнение явно включены оценка калибровки и кросс-доменная проверка.

В результате выбор итоговой модели рассматривается как поиск Парето-компромисса между качеством и ресурсной пригодностью, а не как формальное первенство по одной метрике. Формальная постановка задачи, используемые метрики и математическое описание перечисленных методов приведены во второй главе, а протокол экспериментов, процедура отбора и результаты сравнения – в третьей.

1.4. Выводы по главе

Анализ литературы показывает, что задача приватной интеллектуальной обработки текста в мобильных системах уже рассматривается в исследованиях федеративного обучения и персонализации языковых моделей, однако даже федеративные подходы не снимают всех рисков приватности. Это делает актуальным исследование полностью локальных модулей обработки текста, не требующих передачи ни сообщений, ни обучающих обновлений за пределы устройства.

Вместе с тем задача определения эмоциональной окраски именно коротких русскоязычных сообщений исследована слабее смежных: большинство русскоязычных корпусов и работ ориентированы на тональность отзывов, новостей и отношений к сущностям, а значительная часть доступных данных получена переводом, что порождает вопрос переносимости на нативные тексты. Рассмотренные семейства методов – от словарных и линейных моделей до подсловных, наивно-байесовских и трансформерных – обладают разными компромиссами между качеством, калибровкой, размером и устойчивостью к смене домена.

Поэтому в работе принят подход сравнительного анализа широкого спектра моделей на едином протоколе и по нескольким критериям, с явным учетом калибровки распределений и кросс-доменной проверки, и с последующей демонстрацией прикладного сценария локального анализа эмоциональной окраски переписки. Формальная постановка этой задачи приводится в следующей главе.

Глава 2. Постановка задачи и выбор методов решения

2.1. Формальная постановка задачи

В работе решается задача классификации короткого пользовательского сообщения по эмоциональной окраске. На вход подается текст сообщения x , состоящий, как правило, из одного или нескольких коротких предложений. На выходе требуется получить набор оценок уверенности по всем рассматриваемым эмоциональным классам и итоговую метку. Оценки используются для сравнения классов между собой и последующей агрегации по временным окнам, но не интерпретируются как психологическое измерение состояния пользователя.

В качестве целевой схемы используются семь классов: радость, забота, грусть, злость, тревожность, удивление и нейтральное состояние. Укрупненная схема (семь целевых классов вместо 28 исходных категорий GoEmotions: 27 эмоций и нейтрального класса) выбрана как компромисс между информативностью и устойчивостью классификации на коротких текстах (см. главу 1): слишком детальная разметка нестабильна по качеству и неудобна для интерпретации. Класс «удивление» добавлен к базовому набору эмоций для совместимости с нативным русскоязычным корпусом CEDR, используемым в работе наряду с RuGoEmotions.

Обозначим множество целевых классов через $E = \{e_1, \dots, e_K\}$, где $K = 7$. Формально модель для сообщения x должна возвращать распределение

$$\hat{p}(\cdot | x), \quad \sum_{e \in E} \hat{p}(e | x) = 1, \quad (2.1)$$

а итоговая метка определяется по максимуму этого распределения:

$$\hat{e} = \arg \max_{e \in E} \hat{p}(e | x). \quad (2.2)$$

Конкретный способ получения $\hat{p}(\cdot | x)$ зависит от семейства модели: часть моделей строит распределение через softmax по логитам, а часть задает вероятности иначе. Для постановки задачи важно только, что на выходе получается сопоставимое распределение по одним и тем же семи классам.

Важная особенность постановки состоит в том, что целевая разметка является не одной меткой, а распределением. В исходном корпусе часть сообщений размечена несколькими эмоциями, и при переводе в укрупненную схему масса распределяется между активными классами; кроме того, прикладной сценарий (построение динамики эмоциональной окраски во времени) использует именно распределение оценок по сообщению, а не только доминирующую метку. Поэтому качество модели оценивается в первую очередь по тому, насколько предсказанное распределение по классам близко к целевому.

Для сценария локального применения одной точности классификации недостаточно: модель должна работать на устройстве, давать калиброванные оценки распределения

и иметь малые размер, задержку инференса и потребление памяти. Поэтому задача выбора модели является многокритериальной. Критерии отбора – качество классификации, размер и задержка – имеют разную природу, а их искусственное объединение в одну взвешенную формулу создавало бы ложное ощущение точности; дополнительно оцениваются калибровка распределения и устойчивость к смене домена как свойства, определяющие применимость. В работе используется сравнительный анализ по нескольким критериям (анализ Парето-компромисса), а не вычисление единого рейтинга.

Процедура выбора модели многоэтапна и подробно описана в третьей главе: модели сравниваются на едином лидерборде, затем проверяются на кросс-доменных данных, затем оценивается эффект доменной адаптации, и наконец проводится подбор гиперпараметров на итоговом обучающем наборе. На каждом этапе основной метрикой служит расхождение между предсказанным и целевым распределениями, а сопутствующими – ассурасу, тасго-усредненная F1-мера, калибровочная ошибка и ресурсные характеристики.

2.2. Математический аппарат и обоснование выбранных методов

Далее используются обозначения из раздела 2.1: E – множество эмоциональных классов, $r(e | x)$ – целевое распределение для сообщения x , а $\hat{p}_\theta(e | x)$ – предсказанное распределение модели с параметрами θ . Все рассматриваемые модели приводятся к одному виду «текст $\rightarrow$ распределение по классам», а различаются только способом вычисления $\hat{p}_\theta(e | x)$.

Для обучаемых моделей обучающая выборка имеет вид $\{(x_i, r_i)\}_{i=1}^n$, где $r_i(e) = r(e | x_i)$. Параметры θ подбираются минимизацией регуляризованного эмпирического риска

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n \ell(r_i, \hat{p}_\theta(\cdot | x_i)) + \lambda \Omega(\theta),$$

где для вероятностной классификации в качестве потерь ℓ используется кросс-энтропия по распределению

$$\ell(r_i, \hat{p}_\theta(\cdot | x_i)) = - \sum_{e \in E} r_i(e) \log \hat{p}_\theta(e | x_i),$$

а $\Omega(\theta)$ – регуляризатор. При жесткой разметке r_i является one-hot распределением, и эта формула сводится к обычной кросс-энтропии по истинному классу.

Метрики качества. Для несбалансированных классов основной метрикой качества меток служит тасго-усредненная F1-мера. Для класса e

$$\text{Precision}_e = \frac{TP_e}{TP_e + FP_e}, \quad \text{Recall}_e = \frac{TP_e}{TP_e + FN_e}, \quad F1_e = \frac{2 \text{Precision}_e \text{Recall}_e}{\text{Precision}_e + \text{Recall}_e},$$

$$\text{MacroF1} = \frac{1}{K} \sum_{e \in E} F1_e.$$

Масго-усреднение одинаково учитывает все классы и поэтому не дает редким эмоциям (например, тревожности или удивлению) затеряться на фоне частых.

Однако главной метрикой отбора в работе является не F1, а расхождение между предсказанным и целевым распределениями. Поскольку целевая разметка для объекта i – это распределение r_i , а модель выдает распределение $\hat{p}_i = \hat{p}_\theta(\cdot | x_i)$, естественной мерой служит дивергенция Кульбака–Лейблера:

$$D_{\text{KL}}(r_i \| \hat{p}_i) = \sum_{e \in E} r_i(e) \log \frac{r_i(e)}{\hat{p}_i(e)}. \quad (2.3)$$

На мягких метках это обобщение кросс-энтропии, а на жестких (one-hot) метках KL вырождается в обычный логарифмический проигрыш с точностью до константы. Таким образом, KL напрямую измеряет именно то, что важно для прикладного сценария, – качество всего распределения, а не только доминирующей метки. KL выбрана основной метрикой отбора; рядом всегда приводятся ассигасу и масго-F1 как стандартные показатели качества меток. В таблицах используется среднее значение KL по выборке. На практике перед вычислением KL предсказанные и целевые распределения ограничивались снизу малой величиной $\varepsilon = 10^{-12}$ с повторной нормировкой; это устраняет численную нестабильность при околонулевых вероятностях ($\hat{p}_i(e) \rightarrow 0$) и делает сравнение моделей воспроизводимым.

KL неограничена и резко возрастает, если модель назначает близкую к нулю вероятность истинному классу. Поэтому дополнительно используется ограниченная симметричная мера – дивергенция Йенсена–Шеннона:

$$D_{\text{JS}}(r_i \| \hat{p}_i) = \frac{1}{2} D_{\text{KL}}(r_i \| m_i) + \frac{1}{2} D_{\text{KL}}(\hat{p}_i \| m_i), \quad m_i = \frac{1}{2}(r_i + \hat{p}_i).$$

Поскольку выходные оценки используются как распределение, важна их калибровка. Для ее измерения применяется ожидаемая калибровочная ошибка (ECE): предсказания разбиваются на M интервалов по уверенности, и

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{n} \left| \text{acc}(B_m) - \text{conf}(B_m) \right|, \quad (2.4)$$

где $\text{acc}(B_m)$ и $\text{conf}(B_m)$ – средняя точность и средняя уверенность в интервале B_m . Низкая ECE означает, что уверенность модели согласуется с фактической вероятностью правильного ответа [33]. Поскольку целевая разметка является распределением, для ECE она сворачивается в доминирующую метку через $\arg \max$ целевого распределения, а уверенностью считается максимальная предсказанная вероятность; таким образом, ECE оценивает калибровку уверенности в выбранной метке, тогда как KL – качество всего распределения.

Калибровка температурой. Если модель систематически переуверена, её калибровку можно исправить пост-фактум температурным масштабированием [33]: логиты z_e перед

softmax делятся на единый скаляр $T > 0$,

$$p_T(e | x) = \frac{\exp(z_e/T)}{\sum_{e' \in E} \exp(z_{e'}/T)}.$$

При $T > 1$ распределение становится мягче (уверенность снижается), при $T < 1$ – острее, а $T = 1$ соответствует исходной модели. Деление на положительный скаляр монотонно и не меняет $\arg \max$, поэтому ассурасу, macro-F1 и матрица ошибок сохраняются: калибровка не затрагивает качество выбора метки, изменяя лишь вероятности и, как следствие, ECE и KL. Параметр T подбирается на валидационной выборке. Минимизируемый критерий может быть разным: классический выбор [33] – отрицательное логарифмическое правдоподобие (NLL), то есть та же кросс-энтропия,

$$\text{NLL}(T) = -\frac{1}{n} \sum_{i=1}^n \sum_{e \in E} r_i(e) \log p_T(e | x_i),$$

гладко и выпукло зависящая от $1/T$; альтернатива – прямая минимизация самой ECE. NLL является строго правильным правилом оценки (среди всех предсказателей минимизируется истинными вероятностями), однако температура двигает лишь однопараметрическое семейство и потому даёт ближайшего по KL члена этого семейства, а не сами истинные вероятности; ECE же, будучи бинированной и кусочно-постоянной, шумна, и её прямая минимизация может подстраиваться под случайный шум разбиения. Сравнение обоих критериев приведено в экспериментальной главе.

Семейства моделей. Сравнимые модели охватывают весь спектр сложности.

Словарные модели. Простейшая оценка строится подсчетом совпадений с лексиконем. Пусть L_e – словарь маркеров эмоции e , $T(x)$ – множество нормализованных фрагментов сообщения; тогда

$$c_e(x) = \sum_{t \in T(x)} w_t I(t \in L_e), \quad p(e | x) = \frac{c_e(x) + \alpha}{\sum_{e'} (c_{e'}(x) + \alpha)},$$

где $I(\cdot)$ – индикатор, w_t – вес маркера, α – сглаживание. В ручном лексиконе маркеры и веса заданы экспертно; в обучаемом лексиконе веса оцениваются по данным как логарифмы отношения шансов слова между классами. Словарные модели интерпретируемы и крайне компактны, но слабо учитывают контекст и отрицания.

Линейные модели на TF-IDF. Сообщение представляется разреженным вектором словных и символьных n -грамм со сглаженным TF-IDF-весом

$$\text{tfidf}(t, d) = \text{tf}(t, d) \left(\log \frac{N + 1}{\text{df}(t) + 1} + 1 \right).$$

Поверх признаков обучается линейная модель. В логистической регрессии вероятности задаются softmax,

$$p(e | x) = \frac{\exp(w_e^\top x + b_e)}{\sum_{e'} \exp(w_{e'}^\top x + b_{e'})},$$

с регуляризованной кросс-энтропией в качестве потерь [18, 19]. В гребневой регрессии вместо этого минимизируется квадратичная ошибка относительно мягких меток. Различие существенно для калибровки: логистическая регрессия дает заметно лучше откалиброванные распределения, тогда как гребневая склонна к переуверенности. Символьные n -граммы особенно полезны на коротких текстах с опечатками и разговорными формами.

Подсловная модель. fastText классифицирует текст на основе словных и подсловных признаков, обучая компактные плотные представления и линейный классификатор поверх усредненного представления сообщения [20]:

$$z(x) = \frac{1}{|G(x)|} \sum_{g \in G(x)} v_g, \quad p(e | x) = \text{softmax}(u^\top z(x) + a).$$

Подсловные n -граммы позволяют разделять информацию между родственными словоформами; температурное масштабирование выходов улучшает их калибровку.

Наивный Байес. На тех же TF-IDF-признаках применяется мультиномиальный наивный Байес и его complement-вариант, специально адаптированный к несбалансированным текстовым данным [22]. Это компактные и быстрые классические базовые модели.

Ансамбли деревьев. Для полноты сравнения рассматриваются градиентный бустинг и случайный лес поверх сжатых SVD-представлений TF-IDF [19]. На разреженных текстовых признаках они, как правило, проигрывают линейным моделям и значительно тяжелее по размеру.

Трансформеры. Трансформерные энкодеры строят контекстные представления токенов на основе механизма self-attention [23]:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V.$$

Представление специального классификационного токена h_{cls} подается на линейный слой с softmax. В работе рассматриваются дообученная русскоязычная RuBERT-tiny2 [25, 24] и готовые русскоязычные эмоциональные модели на основе RuBERT и DeBERTa [26]. Трансформеры задают верхнюю планку качества, но имеют существенно больший размер и задержку.

Таким образом, несмотря на разную внутреннюю организацию, все модели приводятся к единому виду «текст $\rightarrow$ распределение по семи классам», что и позволяет сравнивать их на одном протоколе.

2.3. Выводы по главе

Во второй главе задача формализована как многоклассовая классификация коротких сообщений по семи эмоциональным классам с оценкой распределения, а не только итоговой метки. Обоснован выбор основной метрики отбора: поскольку целевая разметка является распределением, а прикладной сценарий использует именно распределение оценок, в

качестве headline-метрики выбрана дивергенция Кульбака–Лейблера, дополненная ассигасу, масго-F1, калибровочной ошибкой ECE и ограниченной JS-дивергенцией. Показано, что выбор модели является многокритериальным и проводится как анализ Парето-компромисса между качеством и ресурсной пригодностью, с дополнительным учётом калибровки и устойчивости к смене домена. Описан математический аппарат всех сравниваемых семейств – от словарных и линейных моделей до подсловных, наивно-байесовских, ансамблей деревьев и трансформеров, – приведенных к единому виду оценки распределения по классам. Это создает основу для экспериментального сравнения в третьей главе.

Глава 3. Реализация и экспериментальная проверка

Ключевая логика главы состоит в переходе от исследовательского вопроса к инженерному выбору модели для локального сценария. Сначала задаётся единый интерфейс и протокол сравнения, затем модели проверяются на исходном и нативном доменах, после чего результат сводится к практическому компромиссу между качеством, калибровкой, размером и задержкой. Главный вывод главы: дообученный трансформер остаётся ориентиром качества, но модель `logreg-char` после добавления небольшого объёма нативных данных оказывается существенно компактнее, быстрее и достаточно точной для приватного локального анализа динамики эмоций.

3.1. Описание реализации

Реализация построена вокруг единого контракта модели, общего конвейера данных и многоэтапной процедуры отбора. Такой подход, а не набор разрозненных скриптов, позволяет сравнивать модели всех семейств – от словарных до трансформерных – в строго одинаковых условиях.

Единый интерфейс и принцип сравнения. Любая модель сводится к одному отображению: на вход подается последовательность текстов сообщений, на выходе возвращается матрица логитов с одной строкой на каждое сообщение и одним столбцом на каждый из $K = 7$ эмоциональных классов, которая нормируется `softmax` в распределение по классам. Благодаря этому интерфейсу словарная базовая модель, линейная модель на TF-IDF, `fastText`, наивный Байес, ансамбль деревьев и дообученный трансформер становятся взаимозаменяемыми и оцениваются одним и тем же кодом. Перед обучением и инференсом все тексты проходят единую нормализацию (приведение регистра, нормализация пробелов, ссылок и упоминаний, перевод части эмодзи в слова-маркеры), что устраняет различия в предобработке между моделями.

Конвейер данных. Прикладной конвейер имеет стабильную границу: экспорт переписки (например, выгрузка диалога из Telegram в формате JSON) преобразуется в табличное представление (CSV) с метаданными (порядковый номер реплики, время, отправитель, текст), после чего модель добавляет к каждой строке распределение оценок по семи классам; сумма оценок в строке равна единице. Метаданные сохраняются неизменными и моделью не используются – она получает только текст. Полученная таблица оценок далее поступает на визуализацию и агрегацию по времени. Такая организация соответствует требованию приватности: после простановки оценок исходный текст для построения динамики уже не ну-

жен.

Протокол оценки. Основной корпус – RuGoEmotions в официальном разбиении (приблизительно 80/10/10); после отображения категорий GoEmotions в семиклассовую схему обучающая часть содержит 43 021 сообщение, валидационная – 5 374, тестовая – сопоставимого объема. Метки мягкие: мультиэмоциональные строки делят вероятностную массу между активными классами. Вторым корпусом является нативный русскоязычный CEDR (около девяти тысяч сообщений): он служит и для оценки переноса на живой русский язык, и как источник нативных данных – часть его обучающей выборки отводится на доменную адаптацию, а остаток – на отложенный тест. Для каждой модели вычисляется единый набор метрик: KL-дивергенция (основная), accuracy, macro-F1, ECE и JS-дивергенция, а также деплой-метрики – размер на диске и задержка инференса на CPU (медиана P50 и 95-й процентиль P95 при пакете размера один). Валидационная часть используется для отбора, тестовая – только для итоговой оценки. Все измерения размера и задержки выполнены в одном окружении на CPU (Apple M4 Pro, 48 ГБ ОЗУ, macOS 26.2, Python 3.14, scikit-learn 1.8, transformers 5.9) и служат для относительного сравнения моделей, а не как прямое измерение на мобильном устройстве.

Процедура выбора победителя. Выбор модели организован как воронка. Сначала лёгкие модели сравниваются на дефолтных гиперпараметрах, затем для них проводится подбор гиперпараметров (HPO) случайным поиском по широкому пространству (суммарно около двух тысяч конфигураций, параллельно). Далее строится единый лидерборд, где лёгкие и тяжёлые модели оцениваются одним протоколом, и трансформеры выступают верхней планкой качества. После этого модели проверяются на нативном CEDR (кросс-домен) и исследуется эффект доменной адаптации. Наконец, на итоговом обучающем наборе выполняется финальный подбор гиперпараметров, и решение принимается как Парето-компромисс между качеством и ресурсной пригодностью, с дополнительным учётом калибровки и устойчивости к смене домена. Реализация выполнена на Python (scikit-learn, fastText, библиотека transformers); ключевые фрагменты кода приведены в приложении А.

3.2. Эксперименты и результаты

3.2.1. Данные и протокол

В работе используются два корпуса. Первый – RuGoEmotions, машинный перевод англоязычного GoEmotions; его категории отображаются в семиклассовую схему, используемую в работе (редкая категория *desire*, не имеющая однозначного эмоционального соответствия, при этом исключается). Соответствие приведено в таблице 3.1. Второй – нативный

русскоязычный корпус CEDR, собранный из реальных русских текстов; это полноправная часть протокола, а не только проверочный набор: на нём оценивается качество на живом русском языке, и из его обучающей части берутся нативные данные для доменной адаптации. В CEDR отсутствует класс «забота», поэтому он покрывает шесть из семи классов; при оценке на нём используется та же семиклассовая выходная схема модели: класс «забота» в целевой разметке CEDR не имеет массы, поэтому модель может предсказывать его, но такие предсказания всегда считаются ошибочными. Это сохраняет совместимость выходного пространства моделей и делает кросс-доменную проверку более строгой. Разметка корпусов различается по «мягкости»: в RuGoEmotions около 11 % сообщений в целевой семиклассовой схеме отнесены более чем к одной эмоции (вероятностная масса делится между классами), тогда как CEDR почти полностью одноклассовый – мультиэмоциональны лишь около 1 % сообщений, а около 40 % не несут явной эмоции и относятся к нейтральному классу. Поэтому целевая величина, с которой по KL сравнивается предсказание, на RuGoEmotions является распределением, а на CEDR близка к одной метке. Для компактности в таблицах далее используются сокращённые обозначения моделей (см. перечень ниже). Отметим, что в полном лидерборде приводятся метрики на валидационной выборке, тогда как в экспериментах по доменной адаптации и итоговому подбору гиперпараметров – на отложенных тестовых выборках соответствующих доменов; этим объясняются небольшие расхождения значений для одной и той же модели между таблицами (например, для `logreg-char` на RuGoEmotions точность составляет 0,591 на валидации и 0,579 на тесте).

Таблица 3.1 – Соответствие исходных категорий GoEmotions целевым классам

Целевой класс	Исходные категории
радость	admiration, amusement, approval, excitement, joy, optimism, pride, relief
забота	caring, gratitude, love
грусть	disappointment, grief, remorse, sadness
злость	anger, annoyance, disapproval, disgust
тревожность	fear, nervousness, embarrassment
удивление	surprise, realization, curiosity, confusion
нейтрально	neutral
— (исключён)	desire

Краткие обозначения моделей.

- `logreg-char` / `-word` / `-union` — TF-IDF на символьных / словных / объединённых n -граммах с логистической регрессией;
- `ridge-char` / `-word` / `-union` — то же с гребневой регрессией;

- **fastText** — нативная fastText supervised с подсловными признаками;
- **nb-multinomial / -complement** — наивный Байес на TF-IDF-признаках;
- **tree-hgb / tree-rf** — градиентный бустинг и случайный лес на SVD-сжатых TF-IDF-признаках;
- **lexicon-learned / -hand** — обучаемый по данным и ручной словарные базовые методы;
- **prior / majority / dummy** — вероятностный, мажоритарный и равномерный тривиальные полы;
- **rubert-tiny2-finetune** — дообученная русскоязычная RuBERT-tiny2;
- **hf-fyaronskiy-deberta, hf-seara-rubert-tiny2, hf-maxkazak-rubert-base** — готовые русскоязычные эмоциональные модели.

3.2.2. Полный лидерборд

В таблице 3.2 приведён единый лидерборд: все модели обучены на RuGoEmotions и оценены одним протоколом на валидации, а столбец «CEDR» показывает accuracy на нативном корпусе. Сортировка – по основной метрике, KL (меньше – лучше). Всего на едином протоколе оценено около двадцати моделей, и все они приведены в таблице.

Таблица 3.2 – Полный лидерборд моделей на едином протоколе

Модель	Тип	Acc	KL	macro-F1	ECE	CEDR Acc	Размер, МБ	P50, мс
rubert-tiny2-finetune	тяж.	0,627	0,965	0,594	0,033	0,597	111,4	1,14
hf-fyaronskiy-deberta	тяж.	0,641	1,004	0,608	0,143	0,647	475,5	11,27
logreg-union	лёг.	0,597	1,043	0,537	0,022	0,498	6,7	0,59
logreg-char	лёг.	0,591	1,060	0,535	0,030	0,494	2,7	0,24
logreg-word	лёг.	0,567	1,135	0,478	0,049	0,456	3,0	0,21
nb-multinomial	лёг.	0,533	1,220	0,446	0,093	0,508	7,2	0,35
tree-hgb	лёг.	0,530	1,222	0,414	0,010	0,465	119,0	24,0
hf-seara-rubert-tiny2	тяж.	0,519	1,321	0,441	0,166	0,493	111,4	3,73
tree-rf	лёг.	0,507	1,330	0,324	0,096	0,448	767,1	16,31
nb-complement	лёг.	0,554	1,464	0,527	0,254	0,526	7,5	0,35
lexicon-learned	лёг.	0,499	1,480	0,433	0,099	0,439	0,04	0,01
fastText	лёг.	0,484	1,520	0,447	0,145	0,390	5,8	0,03
ridge-char	лёг.	0,588	1,545	0,530	0,258	0,507	9,0	0,48
ridge-union	лёг.	0,591	1,631	0,533	0,264	0,506	14,3	0,88
ridge-word	лёг.	0,571	1,632	0,502	0,264	0,471	5,0	0,26
prior (пол)	лёг.	0,296	1,633	0,065	0,018	0,390	0,0	–
lexicon-hand	лёг.	0,364	1,675	0,224	0,064	0,450	0,0	0,01
dummy (пол)	лёг.	0,287	1,869	0,064	0,144	0,188	0,0	–
hf-maxkazak-rubert-base	тяж.	0,464	7,405*	0,353	0,398	0,594	680,2	6,50
majority (пол)	лёг.	0,296	18,923*	0,065	0,704	0,390	0,0	–

* KL завышена из-за несовпадения схемы меток или вырожденного предсказания (maxkazak обучена на иной эмоциональной схеме;

majority всегда предсказывает один класс), поэтому такие модели исключаются из честного сравнения по KL. Тривиальные полы

(dummy, majority, prior) и доминируемые модели приведены для полноты картины.

Основные выводы. По основной метрике лидирует дообученная `rubert-tiny2-finetune` (KL 0,965), за ней – более крупная DeBERTa (KL 1,004) при лучшей ассурасу (0,641), но размере 475 МБ и задержке свыше 11 мс. Среди лёгких моделей лучшими являются линейные на TF-IDF: `logreg-union` (KL 1,043) и `logreg-char` (KL 1,060). Разрыв между лёгкими линейными и трансформером по точности на исходном домене невелик: `logreg-char` (0,591) отстаёт от RuBERT-tiny2 (0,627) примерно на 3,6 п.п. при размере в 40 раз меньше и задержке в 5 раз ниже. Логистическая регрессия – одна из наиболее хорошо откалиброванных практических моделей: её ECE (0,02–0,03) заметно ниже, чем у DeBERTa (0,14), гребневой регрессии (0,26) и `fastText`, и сопоставим с дообученным трансформером (0,03); это важно при использовании распределения для построения динамики. Приведённая в лидерборде ECE измерена до температурной калибровки (её влияние рассмотрено в п. 3.2.6): для выбранной `logreg-char` калибровка практически ничего не меняет (оптимальная $T \approx 1$), тогда как переуверенные модели от неё заметно выигрывают – например, ECE DeBERTa и гребневой регрессии снижается с 0,14 и 0,26 до примерно 0,03 (таблица 3.6). Ансамбли деревьев ожидаемо доминируются: `tree-hgb` при ассурасу 0,530 весит 119 МБ. Тестовые значения KL близки к валидационным (например, `logreg-char` – 1,070 на тесте против 1,060 на валидации), что подтверждает устойчивость оценок.

3.2.3. Кросс-доменная проверка

Высокое качество на исходном домене не гарантирует переносимости. В таблице 3.3 сопоставлена ассурасу моделей, обученных на RuGoEmotions, на валидации (исходный домен) и на нативном CEDR; приведены представители каждого семейства.

Таблица 3.3 – Кросс-доменный разрыв: ассурасу на RuGoEmotions и на нативном CEDR (обучение на RuGoEmotions, 7 классов)

Модель	Асс, RuGo	Асс, CEDR	Разрыв, п.п.
hf-fyaronkiy-deberta	0,641	0,647	–0,6
rubert-tiny2-finetune	0,627	0,597	3,0
nb-multinomial	0,533	0,508	2,5
lexicon-learned	0,499	0,439	6,0
ridge-char	0,588	0,507	8,1
fastText	0,484	0,390	9,4
logreg-char	0,591	0,494	9,7
logreg-union	0,597	0,498	9,9

Картина качественно меняется. Трансформеры почти не теряют на смене домена (DeBERTa даже немного выигрывает, RuBERT-tiny2 теряет около 3 п.п.), тогда как линейные модели на TF-IDF теряют примерно 10 п.п. ассурасу. В результате на нативном русском

разрыв между DeBERTa и логистической регрессией расширяется с примерно 5 до примерно 15 п.п. Это означает, что часть преимущества линейных моделей на исходном домене объясняется не пониманием языка, а подстройкой под особенности машинного перевода: символьные n-граммы переведённого текста хорошо разделяют классы внутри корпуса, но хуже переносятся на живой русский. Любопытно, что наивный Байес оказывается заметно устойчивее линейной регрессии при смене домена (потеря всего 2,5 п.п.), хотя уступает ей на исходном домене. Соответствующие изменения точности показаны на рис. 3.1.




Рис. 3.1 – Кросс-доменный перенос: точность на RuGoEmotions и CEDR; числа над столбцами показывают изменение в п.п.

3.2.4. Доменная адаптация

Возникает вопрос: разрыв на нативном русском вызван нехваткой нативных данных или принципиальным потолком лёгкой модели? Для ответа модели обучались в трёх режимах – только на RuGoEmotions (A), на объединении RuGoEmotions и обучающей части CEDR (B) и только на CEDR (C), – и проверялись на обоих доменах. Результаты приведены в таблице 3.4; в ней показаны по одному представителю каждого семейства, дообучаемый трансформер RuBERT-tiny2 и замороженная DeBERTa как потолок, а полные результаты по всем моделям – в приложении А (таблица А.2).

Таблица 3.4 – Доменная адаптация: accuracy (RuGo / CEDR) по режимам обучения

Модель	A: RuGo	B: RuGo+CEDR	C: CEDR
logreg-char	0,579 / 0,494	0,581 / 0,699	0,361 / 0,718
logreg-union	0,585 / 0,498	0,586 / 0,706	0,360 / 0,711
nb-multinomial	0,539 / 0,508	0,538 / 0,654	0,355 / 0,642
fastText	0,482 / 0,385	0,477 / 0,622	0,321 / 0,713
rubert-tiny2-finetune	0,617 / 0,594	0,616 / 0,776	0,440 / 0,801
hf-fyaronskiy-deberta	0,638 / 0,647	—	—

Режим В оказывается однозначно лучшим: при добавлении около 7,5 тыс. нативных примеров accuracy на CEDR у **logreg-char** вырастает с 0,494 до 0,699 (более чем на 20 п.п.) при практически нулевой потере на RuGoEmotions (0,579 против 0,581). Это показывает, что разрыв на нативном русском был вызван в основном нехваткой нативных данных, а не ёмкостью модели: с нативными данными лёгкая **logreg-char** (CEDR 0,699) обходит даже замороженную DeBERTa (0,647) при размере в 175 раз меньше. Режим С (только CEDR) даёт высокое качество на CEDR, но обрушивает качество на RuGoEmotions (0,361) – то есть нужен именно смешанный набор. Практический вывод: дешевле и эффективнее собрать небольшое количество размеченных данных целевого домена и дообучить лёгкую модель, чем переносить на устройство тяжёлый трансформер. Эффект режима обучения показан на рис. 3.2.




Рис. 3.2 – Доменная адаптация: точность на CEDR в режимах А–С. Пунктир – замороженная DeBERTa.

3.2.5. Итоговый подбор гиперпараметров и выбор модели

С учётом результата доменной адаптации итоговый НПО проводился на объединённом наборе RuGoEmotions + CEDR (около 1500 конфигураций случайным поиском, отбор

по сбалансированной KL); трансформеры в него не включались как дорогие и малочувствительные к этим гиперпараметрам. Ведущие лёгкие семейства и, для сравнения, дообученный RuBERT-tiny2 приведены в таблице 3.5 с полным набором метрик на нативном CEDR; пространство поиска по семействам – в приложении А (таблица А.1).

Таблица 3.5 – Итоговое сравнение на тестовой выборке CEDR после НПО лёгких моделей

Модель	Асс	macro-F1	KL	ECE	Размер, МБ	P50, мс	P95, мс
rubert-tiny2-finetune [†]	0,775	0,595	0,638	0,026	111,4	1,19	1,54
logreg-char	0,722	0,534	0,824	0,057	2,7	0,26	0,39
logreg-union	0,698	0,519	0,878	0,042	37,2	1,71	1,89
ridge-char	0,674	0,471	1,159	0,190	9,1	0,53	0,70
fastText	0,674	0,527	1,029	0,106	5,8	0,04	0,09
nb-multinomial	0,668	0,472	0,938	0,037	2,9	0,27	0,36
lexicon-learned	0,540	0,407	1,436	0,087	0,04	0,01	0,02

[†] RuBERT-tiny2 обучен на RuGoEmotions+CEDR без подбора гиперпараметров и приведён как ориентир качества (НПО затрагивал только лёгкие семейства). Все метрики – на отложенной тестовой выборке CEDR; для RuBERT-tiny2 они получены в калибровочном прогоне и могут незначительно отличаться от таблицы А.2 (тот же режим обучения, другой прогон).

Победителем и итоговым деплой-выбором становится **logreg-char**: на нативном CEDR она достигает ассигуру 0,722 при размере всего 2,7 МБ и задержке 0,26 мс. Её конфигурация: символьные n-граммы `char_wb` длиной от 2 до 6, `max_features` = 30000, сублинейный TF, $C = 2,0$, без взвешивания классов. Близкая **logreg-union** даёт сопоставимое качество (0,698), но в итоговой конфигурации (объединённый корпус, word+char, без ограничения словаря) весит 37 МБ против 6,7 МБ в лидерборде и поэтому доминируется. **fastText** после подбора заметно подрос (CEDR 0,674) и остаётся самым быстрым кандидатом. Дообученный RuBERT-tiny2 остаётся точнее (CEDR 0,775) и лучше откалиброван (ECE 0,026), но весит 111 МБ против 2,7 МБ у **logreg-char**. Таким образом, **logreg-char** не превосходит все альтернативы по каждому отдельному показателю, но образует наилучший Парето-компромисс среди локально запускаемых моделей: лучшее среди лёгких качество на нативном домене при минимальных размере и задержке; вдобавок она хорошо откалибрована. Результат устойчив: при переобучении **logreg-char** на пяти случайных разбиениях обучающих данных метрики на CEDR практически не меняются (расхождения не превышают 0,003 по ассигуру, macro-F1, KL и ECE; в таблице 3.5 приведено значение для основного разбиения), что подтверждает воспроизводимость выбора. Все эксперименты выполнялись при фиксированном начальном значении генератора случайных чисел.

3.2.6. Калибровка уверенности

Поскольку прикладной слой использует не только метку, но и всё распределение оценок (они усредняются при построении динамики), отдельно проверена их калибровка. К обученным моделям применялось температурное масштабирование с подбором T на валидационной выборке; так как температура не меняет $\arg \max$, значения ассурасы и macro-F1 из таблиц 3.2 и 3.5 при этом сохраняются без изменений, а изменяется только ECE.

Результаты подтверждают наблюдение из лидерборда: выбранная `logreg-char` уже хорошо откалибрована (ECE около 0,03, оптимальная $T \approx 1$), поэтому её оценки можно усреднять без поправки. Напротив, переуверенные модели – гребневая регрессия и готовые трансформерные классификаторы – имеют заметно большую ECE, снижаемую температурой в несколько раз при неизменной ассурасы (таблица 3.6).

Таблица 3.6 – Ошибка калибровки ECE до и после температурного масштабирования (валидация RuGoEmotions; ассурасы и macro-F1 не меняются)

Модель	T^*	ECE до	ECE после
<code>logreg-char</code> (выбранная)	1,0	0,030	0,030
<code>ridge-char</code>	2,3	0,258	0,025
<code>hf-fyaronskiy-deberta</code>	1,6	0,143	0,027
<code>hf-maxkazak-rubert-base</code>	4,0	0,398	0,014

Чтобы у уже откалиброванных моделей подбор T не подстраивался под шум бинированной ECE, использовалась зона нечувствительности: T отклоняется от единицы только если выигрыш по валидационной ECE превышает её статистическую погрешность (порядка 0,005 по бутстрапу). Это оставляет `logreg-char` при $T = 1$ и применяет поправку лишь там, где она действительно нужна.

Сравнение критериев подбора температуры. Выбор минимизируемого критерия неочевиден: в работе температура подбирается по самой ECE, тогда как классический подход [33] минимизирует NLL. Чтобы обосновать выбор, оба критерия сопоставлены на всех моделях: для каждой модели температура подбиралась на валидации по ECE и, независимо, по NLL, после чего ECE измерялась на отложенных тестовых выборках обоих доменов (рис. 3.3).




Рис. 3.3 – ECE при подборе температуры по ECE и NLL на RuGoEmotions и CEDR. NLL лучше переносится, но нестабилен на части моделей.

Картина зависит от домена. *In-domain* (RuGoEmotions) прямой подбор по ECE ожидаемо точнее, так как минимизирует именно измеряемую метрику: он даёт меньшую ECE у 14 из 17 нетривиальных моделей. *Кросс-доменно* (нативный CEDR – целевой домен развёртывания) ситуация обратная: подбор по NLL опирается на всё распределение, меньше переобучается под бины исходного домена и переносится лучше – формально у него меньшая ECE на CEDR у 12 из 17 моделей. Однако с учётом статистической погрешности (бутстрап-SE по CEDR около 0,008) уверенно, более чем на 2 SE, выигрывают лишь три модели (DeBERTa, случайный лес и обучаемый лексикон), а остальные различия лежат в пределах шума. По KL – мере качества всего распределения и прямому критерию NLL – подбор по NLL ожидаемо ведёт почти всюду (14 из 17 моделей), но с малыми абсолютными отрывами.

Решающим является поведение в двух крайних случаях (рис. 3.4). У переуверенной модели на нативном домене (DeBERTa, CEDR) подбор по NLL даёт наилучшую калибровку: столбцы точнее всего ложатся на диагональ, а ECE снижается с 0,117 (raw) до 0,055 (по ECE) и до 0,030 (по NLL). Напротив, у модели с нестандартными логитами (fastText, чьи per-label выходы не являются входами softmax) подбор по NLL чрезмерно сглаживает распределение: температура $T = 1,42$ уводит и без того откалиброванную модель в недоуверенность, и ECE растёт с 0,016 до 0,089, тогда как прямой подбор по ECE оставляет её практически нетронутой.




Рис. 3.4 – Диаграммы надёжности DeBERTa и fastText при ECE- и NLL-подборе температуры.

Отсюда следует итоговый выбор. Подбор по NLL теоретически привлекателен (гладкий, строго правильный критерий) и выигрывает кросс-доменно у нескольких моделей и по KL, но небезопасен на моделях с нестандартными логитами и для выбранной деплой-модели `logreg-char` оказывается немного хуже прямого подбора по ECE. Поэтому итоговым критерием выбрана прямая минимизация ECE с зоной нечувствительности: она согласована с сообщаемой метрикой, устойчива на всех моделях и оптимальна именно для развёртываемой модели, тогда как подбор по NLL зафиксирован как разобранная альтернатива. Таким образом, вероятностные оценки выбранной модели пригодны для усреднения при построении эмоциональной динамики без дополнительной калибровочной поправки.

3.3. Эмоциональный таймлайн и концепт календаря

Чтобы проверить применимость выбранной модели на реальных диалогах и заодно получить инструмент для визуального анализа её ошибок, на её основе реализован прикладной слой визуализации динамики эмоциональной окраски переписки. Реализованным артефактом является интерактивное веб-приложение (таймлайн), развёрнутое как технологическая демонстрация на Hugging Face Spaces; эмоциональный календарь рассматривается как концептуальное развитие той же идеи агрегации.

Реализованный таймлайн. Приложение принимает таблицу диалога с проставленными оценками (полученную конвейером «экспорт переписки → реплики → оценки модели») и визуализирует траекторию эмоций по последовательности сообщений: для каждого из семи классов строится кривая его оценки во времени, с переключением между линейным и площадным представлением, фильтрацией по отправителю, выделением отдельной эмоции и сглаживанием по окну. Дополнительно для каждого отправителя выводится агрегированная статистика – среднее распределение эмоций по его сообщениям – и покарточное представление отдельных реплик с их распределениями. Приложение не выполняет инференс и не хранит модель: оно работает с уже проставленными оценками, что соответствует требованию приватности – после простановки оценок исходные тексты для построения динамики не требуются. Пример такой динамики, посчитанной отдельно для каждого участника анонимизированного демонстрационного диалога (с согласия участников) и сопоставленной между выбранной *logreg-char* и дообученным трансформером, приведён на рис. 3.5.




Рис. 3.5 – Эмоциональное распределение демонстрационного диалога: сравнение работы двух моделей для двух участников диалога с 9 июня по 12 июня. Паузы в общении вырезаны для наглядности.

Сопоставление с фабулой диалога. Чтобы проверить, улавливает ли модуль ход реального общения, размеченная динамика сопоставлена с фазами диалога отдельно по участникам. Прослеживается осмысленная и согласованная между обеими моделями траектория:

- *начало* (08.06) – у обоих участников преимущественно нейтрально-радостный фон обычной переписки;
- *напряжение* (09.06) – одновременный для обоих рост долей злости и грусти на фоне интенсивного обмена сообщениями (размолвка): это самый «негативный» участок у

каждого;

- *расхождение к концу* (10–12.06) – участник В заметно теплеет (доля заботы растёт примерно с 0,02 до 0,14, доля злости падает до минимума), тогда как участник А остаётся более сдержанным, с сохраняющейся долей злости.

Показательно, что лёгкая *logreg-char* (нижний ряд) воспроизводит ту же картину, что и дообученный трансформер (верхний ряд). При этом доминирующей меткой почти везде остаётся нейтральность, а эмоциональная динамика проявляется в долях остальных классов, – что согласуется с назначением модуля как инструмента агрегированного анализа, а не точной диагностики отдельного сообщения.

Принцип агрегации. Как для сглаживания таймлайна, так и для календаря используется не голосование по итоговым меткам, а усреднение выходных распределений модели. Пусть в некотором окне находится n сообщений, и для сообщения i модель возвращает оценку $s_i(e)$ для эмоции e . Тогда

$$\bar{s}(e) = \frac{1}{n} \sum_{i=1}^n s_i(e), \quad e^* = \arg \max_e \bar{s}(e).$$

Усреднение распределений сохраняет информацию о близких по величине классах и согласуется с принципом линейного комбинирования выходов классификаторов [37], тогда как голосование по меткам эту информацию теряет. Сама идея оценки динамики во времени опирается на подход повторных измерений состояния в естественной среде [35] и на текстовую агрегацию эмоциональных оценок по временным интервалам [36]. При интерпретации значений учитывается, что выходные оценки могут быть неидеально откалиброваны [33], поэтому они используются как относительная уверенность, а не как психологическое измерение.

Концепт календаря. Естественным развитием таймлайна является эмоциональный календарь – агрегация по тому же принципу, но по календарным ячейкам: сообщения отправителя группируются по датам и периодам дня (утро, день, вечер), и для каждой ячейки усреднённое распределение даёт доминирующую эмоцию, уверенность и число сообщений. Для построения такого календаря достаточно хранить агрегированные статистики ячеек, а не исходные сообщения, что делает его пригодным для приватного локального сценария. В текущей работе календарь представлен как концепция агрегации; реализованным и продемонстрированным артефактом является таймлайн.

Практическая архитектура. Практически такой модуль естественно разделяется на два слоя: локальный инференс, преобразующий текст сообщения в распределение по эмоциям, и визуализационный слой, работающий только с числовыми оценками. Это позволяет удалить

исходный текст сразу после получения оценок и хранить лишь агрегированные статистики, обеспечивая приватность по построению. Слой локального инференса невелик и не требует сети, поэтому может быть встроен в существующую открытую офлайн-клавиатуру (например, HeliBoard, работающую полностью без доступа в интернет [38]), что делает практическую интеграцию реалистичной без разработки клавиатуры с нуля.

3.4. Анализ результатов

Чтобы понять, какие классы распознаются устойчиво, а какие смешиваются, для выбранной `logreg-char` рассчитаны метрики по классам (таблица 3.7) и матрица ошибок в виде тепловой карты (рис. 3.6).

Таблица 3.7 – Качество `logreg-char` по классам (7 классов, валидация)

Класс	Precision	Recall	F1	Размер класса
радость	0,664	0,681	0,672	1543
забота	0,724	0,609	0,661	619
грусть	0,586	0,393	0,470	313
злость	0,541	0,416	0,470	702
тревожность	0,791	0,321	0,456	106
удивление	0,504	0,347	0,411	499
нейтрально	0,528	0,707	0,604	1592

Лучше всего распознаются частые и лексически выраженные классы – радость (F1 0,672), забота (0,661) и нейтральное состояние (0,604). Труднее всего – грусть, злость, тревожность и удивление (F1 0,41–0,47). Характерная ошибка – утечка в нейтральный класс: например, из 702 сообщений злости 292 распознаны верно, но 275 отнесены к нейтральному. Тревожность и удивление систематически недопредсказываются (recall 0,32 и 0,35): при высокой точности тревожности (0,791) модель распознаёт лишь треть таких сообщений. Часты также взаимные ошибки радость ↔ забота и радость ↔ нейтрально. Анализ самых уверенных ошибок вскрывает две причины: шум разметки (например, сообщение «Печаль. Печаль.» размечено как нейтральное, тогда как модель уверенно и по сути верно предсказывает грусть) и объективную неоднозначность близких классов («Рад слышать это» на границе радости и заботы; «Ух ты, круто!» на границе удивления и радости). Это показывает, что задача не является идеально делимой и результат подходит не для точной диагностики отдельного сообщения, а для агрегированного анализа, где случайные ошибки частично сглаживаются усреднением.




Рис. 3.6 – Нормированная матрица ошибок logreg-char: цвет – recall, число – количество сообщений.

Как показано выше, logreg-char хорошо откалибрована на исходном домене; на нативном домене (CEDR) лучшую калибровку показывают RuBERT-tiny2 и наивный Байес, а logreg-char сохраняет приемлемый уровень (ECE 0,06, таблица 3.5). Для построения динамики, где используется само распределение, такой уровень калибровки в сочетании с лучшим среди лёгких моделей качеством делает logreg-char практичным выбором.

Чтобы понять, ограничена ли модель объёмом данных, построена кривая обучения (таблица 3.8). Качество выходит на плато: переход от 20 тыс. к 39 тыс. обучающих примеров добавляет лишь около 1,4 п.п. ассигасу против 3,6 п.п. на участке 2–5 тыс. Это означает, что разрыв до трансформеров на исходном домене определяется ёмкостью модели, а не нехваткой данных; при этом, как показано выше, на нативном домене решающим оказывается именно добавление небольшого объёма данных целевого домена. Кривая обучения приведена на рис. 3.7.




Рис. 3.7 – Кривая обучения logreg-char: качество выходит на плато после примерно 20 тыс. примеров.

Таблица 3.8 – Кривая обучения logreg-char: качество на валидации

Объем обучения	Асс	macro-F1	KL
2 000	0,488	0,316	1,320
5 000	0,524	0,388	1,221
10 000	0,556	0,467	1,147
20 000	0,574	0,508	1,106
39 055	0,588	0,532	1,064

3.5. Сводное сравнение и применимость

Сведём результаты воедино с точки зрения применимости в локальном сценарии. Сравнение моделей – это компромисс между качеством и ресурсами, а не первенство по одной метрике. Трансформеры задают верхнюю планку качества и устойчивы к смене домена, но покупают эти свойства ценой размера в десятки и сотни мегабайт и задержки в единицы и десятки миллисекунд: DeBERTa – 475 МБ и более 11 мс, дообученная RuBERT-tiny2 – 111 МБ и около 1 мс. Лёгкие линейные модели на порядки компактнее и быстрее (logreg-char – 2,7 МБ и 0,26 мс), хорошо откалиброваны и, при наличии небольшого объёма нативных данных, почти догоняют трансформер по качеству на целевом домене (CEDR 0,699–0,722 против 0,776 у RuBERT-tiny2). Итоговая логика выбора компактно приведена в таблице 3.9, а соотношение качества и ресурсов – на рис. 3.8.

Таблица 3.9 – Итоговый выбор модели для локального сценария

Модель	Acc, CEDR	KL, CEDR	Размер, МБ	P95, мс	Роль в выборе
rubert-tiny2-finetune	0,775	0,638	111,4	1,54	Ориентир качества, но существенно тяжелее локального кандидата.
logreg-char	0,722	0,824	2,7	0,39	Итоговый выбор: малый размер, низкая задержка, приемлемое качество и калибровка.
logreg-union	0,698	0,878	37,2	1,89	Близкое качество, но заметно больший артефакт и задержка.
nb-multinomial	0,668	0,938	2,9	0,36	Компактен, но уступает по ассигасу и маско-F1.
fastText	0,674	1,029	5,8	0,09	Очень быстрый, но хуже по качеству распределения и калибровке.



Рис. 3.8 – Качество и ресурсы моделей: размер круга – P95, цвет – тип модели, выделена **logreg-char**. Доминируемые выбросы исключены.

Именно в этом сравнении возвращается мотив локального, в том числе мобильного, применения. Для модуля, работающего на устройстве пользователя, критичны размер артефакта, задержка отклика и отсутствие передачи данных наружу. По совокупности этих критериев итоговым выбором становится **logreg-char**: при размере 2,7 МБ и задержке доли миллисекунды она пригодна для полностью локального запуска, даёт калиброванное распределение, необходимое для построения динамики, и – после дообучения на нативных данных – достигает качества, сопоставимого с трансформерным. Трансформер при этом сохраняет роль ориентира качества: если ресурсные ограничения смягчаются, дообученная RuBERT-tiny2 даёт лучшее распределение (KL 0,965). Таким образом, выбор модели определяется качеством распределения, калибровкой, устойчивостью на нативном домене, размером артефакта, задержкой и возможностью полностью локального запуска.

3.6. Ограничения, этика и приватность

Результаты работы следует интерпретировать с учётом нескольких границ применимости. Они не отменяют основной вывод, но задают условия, при которых его корректно переносить на практические сценарии.

1. **Валидность данных.** RuGoEmotions является переводным корпусом, поэтому часть лексических признаков может отражать особенности машинного перевода, а не естественной русской переписки. Этот эффект явно измерен кросс-доменной проверкой и частично компенсируется доменной адаптацией.
2. **Внешняя валидность.** CEDR собран из публичных источников и не содержит класса «забота», поэтому покрывает личную переписку лишь приближённо. Для промышленного внедрения потребуется целевая выборка конкретного домена: мессенджера, языка общения и пользовательского сценария.
3. **Валидность измерений.** Размер модели и задержка инференса измерены в едином экспериментальном окружении на CPU. Они пригодны для относительного сравнения моделей, но не являются прямой гарантией задержки на конкретном мобильном устройстве.
4. **Интерпретационная валидность.** Модуль определяет эмоциональную окраску текста, а не реальное психологическое состояние человека. Сарказм, цитирование, шутки, контекст вне сообщения и индивидуальная манера письма могут менять смысл предсказаний.
5. **Демонстрационный диалог.** Рисунок 3.5 показывает, как таймлайн выглядит на одном анонимизированном диалоге, но по нему не оценивается качество модели. Все количественные выводы о точности, калибровке и переносимости сделаны по корпусам RuGoEmotions и CEDR.

Этическое ограничение является принципиальным: такая функция не должна использоваться для диагностики, оценки работника или скрытого профилирования. В практическом продукте анализ должен включаться только по явному согласию пользователя; агрегированные данные должны быть доступны для удаления; исходные сообщения не должны сохраняться после простановки оценок и попадать в логи; в чувствительных полях ввода (пароли, одноразовые коды, банковские реквизиты) анализ должен отключаться.

3.7. Выводы по главе

В третьей главе экспериментально показано, что локальный сценарий анализа эмоциональной окраски реалистичен без переноса тяжёлого трансформера на устройство. Единый протокол сравнения выявил верхнюю планку качества у дообученной RuBERT-tiny2, но одновременно показал, что `logreg-char` близка к ней на исходном домене, хорошо откалибрована и на порядки компактнее. Кросс-доменная проверка зафиксировала слабое место линейных моделей – потерю около 10 п.п. ассигасу на нативном русском, – а эксперимент по доменной адаптации показал, что эта потеря в основном устраняется добавлением небольшого объёма нативных данных. После итогового НПО `logreg-char` достигает CEDR-ассигасу 0,722 при размере 2,7 МБ и P95 0,39 мс, поэтому становится обоснованным деплой-выбором. На её основе реализован прикладной таймлайн динамики эмоциональной окраски переписки и описан концепт эмоционального календаря.

Заключение

В ходе работы исследована задача локального определения эмоциональной окраски коротких русскоязычных сообщений в сценарии приватной обработки текстового ввода. Центральный результат состоит в том, что такой сценарий можно реализовать без серверной обработки и без обязательного переноса тяжёлого трансформера на устройство: при корректном протоколе сравнения лёгкая линейная модель оказывается достаточно точной, компактной и быстрой для агрегированного анализа динамики.

В работе показано, что применимость модели определяется не одной метрикой ассурасу, а совокупностью характеристик: качеством распределения по классам, калибровкой оценок, устойчивостью к смене домена, размером артефакта и задержкой инференса. Поэтому задача была формализована как семиклассовая классификация с оценкой распределения, а в качестве основной метрики отбора использована KL-дивергенция, дополненная ассурасу, macro-F1, ECE и ресурсными метриками. На корпусах RuGoEmotions и CEDR по единому протоколу сопоставлено около двадцати моделей – от словарных и линейных базовых методов до готовых и дообучаемых трансформеров.

Эксперименты подтвердили ожидаемую верхнюю планку качества у дообученной RuBERT-tiny2, но также показали практическую силу `logreg-char`: на исходном домене она почти догоняет трансформер, хорошо откалибрована и на порядки компактнее. Кросс-доменная проверка выявила потерю качества линейных моделей на нативном русском, однако эксперимент по доменной адаптации показал, что разрыв в основном связан с нехваткой нативных данных и сокращается добавлением небольшой целевой выборки. После итогового подбора гиперпараметров `logreg-char` достигает CEDR-ассурасу 0,722 при размере 2,7 МБ и P95 0,39 мс, что делает её обоснованным выбором для локального прототипа. Трансформер при этом сохраняет роль ориентира качества при ослаблении ресурсных ограничений.

На основе выбранной модели реализован прикладной модуль визуализации динамики эмоциональной окраски переписки – эмоциональный таймлайн, – а также описан концепт эмоционального календаря. Оба сценария используют усреднение выходных распределений модели по временным окнам, поэтому для построения динамики достаточно хранить агрегированные статистики, а не исходные тексты сообщений. Это связывает экспериментальный выбор модели с исходной мотивацией работы: приватным локальным анализом без передачи пользовательских сообщений наружу.

Ограничения работы связаны с несовпадением корпусных данных с реальной личной перепиской, переводной природой RuGoEmotions, приближённостью CEDR к целевому домену и тем, что задержки измерялись в экспериментальном окружении, а не на конкретном мобильном устройстве. Эти ограничения задают направления дальнейшей работы: сбор

размеченной выборки целевого диалогового домена, дополнительная проверка калибровки, экспорт выбранной модели и измерения непосредственно на мобильном устройстве. Поставленные во введении задачи решены полностью:

1. проведён обзор подходов и моделей эмоциональной классификации коротких текстов;
2. сформирован единый протокол сравнения – семиклассовая схема, набор метрик (KL, accuracy, macro-F1, ECE) и корпуса RuGoEmotions и CEDR, включая кросс-доменную проверку;
3. на едином протоколе с подбором гиперпараметров сопоставлено около двадцати моделей и по совокупности критериев выбрана logreg-char;
4. исследованы устойчивость моделей к смене домена и эффект доменной адаптации, выявившие как масштаб разрыва, так и способ его сокращения;
5. реализован прикладной модуль визуализации динамики эмоциональной окраски (эмоциональный таймлайн) и описан концепт эмоционального календаря.

Таким образом, результат работы представляет собой исследовательски обоснованный и инженерно проверенный прототип локального анализа эмоциональной окраски сообщений, в котором приватность достигается архитектурно, а выбор модели подтверждён сравнением качества, калибровки и ресурсов.

Список использованных источников

- [1] Hard A. [и др.]. Federated Learning for Mobile Keyboard Prediction [Электронный ресурс]. – arXiv:1811.03604. – 2018. – URL: <https://arxiv.org/abs/1811.03604> (дата обращения: 11.06.2026).
- [2] Wang K. [и др.]. Federated Evaluation of On-device Personalization [Электронный ресурс]. – arXiv:1910.10252. – 2019. – URL: <https://arxiv.org/abs/1910.10252> (дата обращения: 11.06.2026).
- [3] Suliman M., Leith D. Two Models are Better than One: Federated Learning Is Not Private For Google GBoard Next Word Prediction [Электронный ресурс]. – arXiv:2210.16947. – 2022. – URL: <https://arxiv.org/abs/2210.16947> (дата обращения: 11.06.2026).
- [4] Baziotis C. [и др.]. NTUA-SLP at SemEval-2018 Task 1: Predicting Affective Content in Tweets with Deep Attentive RNNs and Transfer Learning [Электронный ресурс]. – arXiv:1804.06658. – 2018. – URL: <https://arxiv.org/abs/1804.06658> (дата обращения: 11.06.2026).
- [5] Felbo B. [и др.]. Using Millions of Emoji Occurrences to Learn Any-domain Representations for Detecting Sentiment, Emotion and Sarcasm [Электронный ресурс]. – arXiv:1708.00524. – 2017. – URL: <https://arxiv.org/abs/1708.00524> (дата обращения: 11.06.2026).
- [6] Demszky D. [и др.]. GoEmotions: A Dataset of Fine-Grained Emotions [Электронный ресурс]. – arXiv:2005.00547. – 2020. – URL: <https://arxiv.org/abs/2005.00547> (дата обращения: 11.06.2026).
- [7] Seara. RuGoEmotions: русскоязычная адаптация набора GoEmotions [Электронный ресурс]. – Hugging Face Datasets. – URL: https://huggingface.co/datasets/seara/ru_go_emotions (дата обращения: 12.06.2026).
- [8] Volansky V., Ordan N., Wintner S. On the Features of Translationese // Digital Scholarship in the Humanities. – 2015. – Vol. 30, no. 1. – P. 98–118. – DOI: 10.1093/lle/fqt031.
- [9] Sboev A., Naumov A., Rybka R. Data-Driven Model for Emotion Detection in Russian Texts // Procedia Computer Science. – 2021. – Vol. 190. – P. 637–642. – DOI: 10.1016/j.procs.2021.06.075.
- [10] Kotelnikov E. Current Landscape of the Russian Sentiment Corpora [Электронный ресурс]. – arXiv:2106.14434. – 2021. – URL: <https://arxiv.org/abs/2106.14434> (дата обращения: 11.06.2026).

- [11] Loukachevitch N., Rusnachenko N. Sentiment Frames for Attitude Extraction in Russian [Электронный ресурс]. – arXiv:2006.10973. – 2020. – URL: <https://arxiv.org/abs/2006.10973> (дата обращения: 13.06.2026).
- [12] Mohammad S. M., Turney P. D. Crowdsourcing a Word-Emotion Association Lexicon [Электронный ресурс]. – arXiv:1308.6297. – 2013. – URL: <https://arxiv.org/abs/1308.6297> (дата обращения: 11.06.2026).
- [13] Шаховский В. И. Лингвистическая теория эмоций. – М. : Гнозис, 2008. – 416 с.
- [14] Бабенко Л. Г. Лексические средства обозначения эмоций в русском языке. – Свердловск : Изд-во Уральского университета, 1989. – 184 с.
- [15] Kotelnikova A. [и др.]. Lexicon-based Methods vs. BERT for Text Sentiment Analysis [Электронный ресурс]. – arXiv:2111.10097. – 2021. – URL: <https://arxiv.org/abs/2111.10097> (дата обращения: 13.06.2026).
- [16] Salton G., Buckley C. Term-weighting Approaches in Automatic Text Retrieval // Information Processing & Management. – 1988. – Vol. 24, no. 5. – P. 513–523. – DOI: 10.1016/0306-4573(88)90021-0.
- [17] Manning C. D., Raghavan P., Schütze H. Introduction to Information Retrieval [Электронный ресурс]. – Cambridge : Cambridge University Press, 2008. – 482 p. – URL: <https://nlp.stanford.edu/IR-book/> (дата обращения: 19.06.2026).
- [18] Cox D. R. The Regression Analysis of Binary Sequences // Journal of the Royal Statistical Society. Series B. – 1958. – Vol. 20, no. 2. – P. 215–242.
- [19] Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction [Электронный ресурс]. – 2nd ed. – New York : Springer, 2009. – 745 p. – URL: <https://hastie.su.domains/ElemStatLearn/> (дата обращения: 19.06.2026).
- [20] Joulin A. [и др.]. Bag of Tricks for Efficient Text Classification [Электронный ресурс]. – arXiv:1607.01759. – 2016. – URL: <https://arxiv.org/abs/1607.01759> (дата обращения: 11.06.2026).
- [21] Joulin A. [и др.]. FastText.zip: Compressing Text Classification Models [Электронный ресурс]. – arXiv:1612.03651. – 2016. – URL: <https://arxiv.org/abs/1612.03651> (дата обращения: 11.06.2026).
- [22] Rennie J. D. M. [и др.]. Tackling the Poor Assumptions of Naive Bayes Text Classifiers // Proceedings of the Twentieth International Conference on Machine Learning (ICML). – Washington : AAAI Press, 2003. – P. 616–623.

- [23] Vaswani A. [и др.]. Attention Is All You Need [Электронный ресурс]. – arXiv:1706.03762. – 2017. – URL: <https://arxiv.org/abs/1706.03762> (дата обращения: 19.06.2026).
- [24] Devlin J. [и др.]. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding [Электронный ресурс]. – arXiv:1810.04805. – 2019. – URL: <https://arxiv.org/abs/1810.04805> (дата обращения: 19.06.2026).
- [25] Kuratov Y., Arkhipov M. Adaptation of Deep Bidirectional Multilingual Transformers for Russian Language [Электронный ресурс]. – arXiv:1905.07213. – 2019. – URL: <https://arxiv.org/abs/1905.07213> (дата обращения: 19.06.2026).
- [26] He P. [и др.]. DeBERTa: Decoding-enhanced BERT with Disentangled Attention [Электронный ресурс]. – arXiv:2006.03654. – 2020. – URL: <https://arxiv.org/abs/2006.03654> (дата обращения: 20.06.2026).
- [27] Sanh V. [и др.]. DistilBERT, a Distilled Version of BERT: Smaller, Faster, Cheaper and Lighter [Электронный ресурс]. – arXiv:1910.01108. – 2019. – URL: <https://arxiv.org/abs/1910.01108> (дата обращения: 11.06.2026).
- [28] Sun Z. [и др.]. MobileBERT: a Compact Task-Agnostic BERT for Resource-Limited Devices [Электронный ресурс]. – arXiv:2004.02984. – 2020. – URL: <https://arxiv.org/abs/2004.02984> (дата обращения: 11.06.2026).
- [29] Panopoulos I. [и др.]. Exploring the Performance and Efficiency of Transformer Models for NLP on Mobile Devices [Электронный ресурс]. – arXiv:2306.11426. – 2023. – URL: <https://arxiv.org/abs/2306.11426> (дата обращения: 11.06.2026).
- [30] Rahman M. W. U. [и др.]. Quantized Transformer Language Model Implementations on Edge Devices [Электронный ресурс]. – arXiv:2310.03971. – 2023. – URL: <https://arxiv.org/abs/2310.03971> (дата обращения: 11.06.2026).
- [31] Razova E., Vychezhzhanin S., Kotelnikov E. Does BERT Look at Sentiment Lexicon? [Электронный ресурс]. – arXiv:2111.10100. – 2021. – URL: <https://arxiv.org/abs/2111.10100> (дата обращения: 13.06.2026).
- [32] Golubev A., Rusnachenko N., Loukachevitch N. RuSentNE-2023: Evaluating Entity-Oriented Sentiment Analysis on Russian News Texts [Электронный ресурс]. – arXiv:2305.17679. – 2023. – URL: <https://arxiv.org/abs/2305.17679> (дата обращения: 13.06.2026).
- [33] Guo C. [и др.]. On Calibration of Modern Neural Networks [Электронный ресурс]. – arXiv:1706.04599. – 2017. – URL: <https://arxiv.org/abs/1706.04599> (дата обращения: 13.06.2026).

- [34] Ramponi A., Plank B. Neural Unsupervised Domain Adaptation in NLP – A Survey [Электронный ресурс] // Proceedings of the 28th International Conference on Computational Linguistics (COLING). – 2020. – P. 6838–6855. – DOI: 10.18653/v1/2020.coling-main.603. – URL: <https://aclanthology.org/2020.coling-main.603/> (дата обращения: 20.06.2026).
- [35] Shiffman S., Stone A. A., Hufford M. R. Ecological Momentary Assessment // Annual Review of Clinical Psychology. – 2008. – Vol. 4. – P. 1–32. – DOI: 10.1146/annurev.clinpsy.3.022806.091415.
- [36] Dodds P. S. [и др.]. Temporal Patterns of Happiness and Information in a Global Social Network: Hedonometrics and Twitter // PLOS ONE. – 2011. – Vol. 6, no. 12. – P. e26752. – DOI: 10.1371/journal.pone.0026752.
- [37] Tumer K., Ghosh J. Linear and Order Statistics Combiners for Pattern Classification [Электронный ресурс]. – arXiv:cs/9905012. – 1999. – URL: <https://arxiv.org/abs/cs/9905012> (дата обращения: 13.06.2026).
- [38] HeliBoard: Customizable and Privacy-conscious Open-source Keyboard [Электронный ресурс]. – URL: <https://github.com/Helium314/HeliBoard> (дата обращения: 22.06.2026).

ПРИЛОЖЕНИЕ А

Дополнительные таблицы и фрагменты программной реализации

В приложении собраны материалы, которые поддерживают воспроизводимость экспериментов, но перегружали бы основной текст: пространство поиска гиперпараметров, полные результаты доменной адаптации и ключевые фрагменты программной реализации. Полный код размещён в репозиториях проекта: `dialog-emo-models` (обучение и инференс моделей) и `dialog-emo-demo` (демонстрационное приложение визуализации).

Дополнительные таблицы

Таблица A.1 фиксирует, какие гиперпараметры подбирались для каждого семейства моделей. Это делает процедуру НРО проверяемой: итоговый выбор `logreg-char` является результатом сравнения внутри заранее заданного пространства, а не ручной настройки одной модели.

Таблица A.1 – Пространство поиска гиперпараметров по семействам (случайный поиск, отбор по сбалансированной KL)

Семейство	Подбираемые гиперпараметры
logreg (char/word/union)	ngram_range, max_features, min_df, sublinear_tf, C, class_weight
ridge (char/word/union)	ngram_range, max_features, min_df, sublinear_tf, alpha
fastText	lr, epoch, dim, wordNgrams, minn/maxn, loss
nb	тип (multinomial/complement), analyzer, ngram_range, max_features, min_df, sublinear_tf, alpha
lexicon-learned	top_k, min_count, alpha
tree (hgb/rf)	число компонент SVD, max_depth, n_estimators

Таблица A.2 раскрывает полный результат доменной адаптации. В основной главе приведены представители семейств, а здесь сохранены все модели, чтобы было видно, что вывод о пользе нативных данных не зависит от одного выбранного кандидата.

Таблица A.2 – Полные результаты доменной адаптации (режим обучения В: RuGoEmotions+CEDR), все семейства; † – готовые модели без дообучения. Метрики – на тестовых выборках соответствующих доменов.

Модель	Acc, RuGo	Acc, CEDR	macro-F1, CEDR	KL, CEDR
rubert-tiny2-finetune	0,616	0,776	0,599	0,648
logreg-union	0,586	0,706	0,526	0,875
ridge-union	0,584	0,701	0,530	1,189
logreg-char	0,581	0,699	0,526	0,865
ridge-char	0,585	0,696	0,522	1,188
nb-complement	0,552	0,681	0,498	1,253
nb-multinomial	0,538	0,654	0,454	0,963
hf-fyaronskiy-deberta [†]	0,638	0,647	0,512	1,019
fastText	0,477	0,622	0,488	1,856
ridge-word	0,561	0,607	0,437	1,527
hf-maxkazak-rubert-base [†]	0,476	0,594	0,481	3,485
logreg-word	0,555	0,589	0,407	1,151
tree-hgb	0,521	0,563	0,368	1,224
lexicon-learned	0,507	0,535	0,386	1,460
tree-rf	0,494	0,513	0,283	1,396
hf-seara-rubert-tiny2 [†]	0,520	0,493	0,364	1,459
lexicon-hand	0,366	0,450	0,268	1,715
prior	0,299	0,390	0,094	1,792

Фрагменты реализации

Листинги ниже показывают не полный проект, а ключевые интерфейсные точки: единый контракт модели, преобразование экспорта переписки в таблицу оценок и обучение выбранной модели. Именно эти фрагменты связывают экспериментальную часть с прикладным прототипом.

Листинг 1. Единый интерфейс модели

Единый интерфейс делает разные семейства моделей взаимозаменяемыми: каждая модель возвращает логиты, которые затем нормируются в распределение по эмоциональным классам.

```

from abc import ABC, abstractmethod
from typing import Sequence

import numpy as np
from numpy.typing import NDArray

from dialog_emo_models.schema import EMOTIONS

```

```

class EmotionModel(ABC):
    """Единый контракт всех моделей: текст -> logits по классам."""

    def fit(self, texts, labels=None):
        return self

    @abstractmethod
    def predict_logits(self, texts: Sequence[str]) -> NDArray[np.float64]:
        """Возвращает массив формы (len(texts), len(EMOTIONS))."""

    def predict_proba(self, texts: Sequence[str]) -> NDArray[np.float64]:
        logits = self.predict_logits(texts)
        return logits_to_probabilities(logits)

def logits_to_probabilities(
    logits: NDArray[np.float64],
) -> NDArray[np.float64]:
    if logits.shape[0] == 0:
        return logits.copy()
    shifted = logits - logits.max(axis=1, keepdims=True)
    exps = np.exp(shifted)
    return exps / exps.sum(axis=1, keepdims=True)

```

Листинг 2. Конвейер инференса: от экспорта переписки к таблице оценок

Конвейер отделяет метаданные диалога от текста и сохраняет на выходе только числовые оценки по эмоциям, что соответствует приватному сценарию визуализации.

```

import pandas as pd

from dialog_emo_models.models import EmotionModel
from dialog_emo_models.schema import (
    EMOTIONS, validate_full_frame, validate_parsed_frame)
from dialog_emo_models.telegram import load_telegram_export

def parse_telegram_json(path) -> pd.DataFrame:
    # экспорт переписки -> таблица (turn_index, timestamp, sender, text)

```

```

return load_telegram_export(path)

def score_parsed_frame(
    frame: pd.DataFrame,
    model: EmotionModel,
) -> pd.DataFrame:
    parsed = validate_parsed_frame(frame)
    probabilities = model.predict_proba(parsed["text"].tolist())

    scored = parsed.copy()
    for index, emotion in enumerate(EMOTIONS):
        scored[emotion] = probabilities[:, index]    # сумма по строке = 1
    return validate_full_frame(scored)

```

Листинг 3. Обучение выбранной модели и агрегация распределений

Последний листинг показывает итоговую лёгкую конфигурацию и принцип агрегации: динамика строится по среднему распределению в окне, а не по голосованию жёстких меток.

```
import numpy as np
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.linear_model import LogisticRegression
from sklearn.pipeline import Pipeline

def train_logreg_char(texts, labels):
    # итоговая конфигурация: TF-IDF на символьных n-граммах + logreg
    pipeline = Pipeline([
        ("tfidf", TfidfVectorizer(
            analyzer="char_wb", ngram_range=(2, 6),
            max_features=30000, min_df=1, sublinear_tf=True)),
        ("clf", LogisticRegression(
            C=2.0, class_weight=None, max_iter=2000)),
    ])
    pipeline.fit(texts, labels)
    return pipeline

def aggregate_window(scores: np.ndarray):
    # scores: (n_сообщений, n_классов) распределения за временное окно
    mean = scores.mean(axis=0)
    dominant = int(mean.argmax())
    return dominant, float(mean[dominant]), mean
```